

ISB206 Veri Madenciliği

11.02.2026

1. Ders için Öğrenim Amaçları

1. Veri madenciliği ortaya çıkış nedenleri
2. Temel tanımlar
3. Veri madenciliğinde kullanılan yöntemler
4. Veri madenciliği yanlışları
5. Kaggle web sayfası

Neden veri madenciliğine ihtiyaç duyuldu?

- ▶ Depolanan veri miktarındaki artış.
- ▶ Özellikle internet sayesinde farklı verilere kolay ulaşım sağlanması.
- ▶ Bilgisayarların hesap kapasitelerindeki artış.

Tanımlar

Tanım (Veri Madenciliği)

Büyük veri kümelerinde yararlı örüntüleri ve eğilimleri keşfetme sürecidir.

Tanım (Büyük Veri)

Büyük veri, esas olarak geleneksel veri işleme yazılımları tarafından işlenemeyecek kadar büyük veya karmaşık olan veri kümelerini ifade eder.

Tanım (Örüntü)

Veri madenciliğinde örüntü, kolayca tanıyabileceğimiz bir şekil veya yapıyı gösteren veri noktaları dizisidir.

Genel anlamda veri madenciliği İstatistik, Makine Öğrenme ve Veri Tabanı alanlarında kullanılan tekniklerin birleşmesi ile oluşmuştur.

Veri Madenciliği için Endüstriler Arası Standard Süreç: CRISP-DM

- ▶ CRISP-DM Daimler-Chrysler, SPSS ve NCR analistlerinin ortak çalışması ile geliştirilmiştir.
- ▶ Bu sürecin amacı, veri madenciliği uygulamaları için endüstri ve yapılacak araştırma konusundan bağımsız bir süreç şablonu oluşturmaktır.
- ▶ Bu süreç altı adımdan oluşmaktadır.

CRISP-DM Adımları

1. Araştırmayı Anlama

- ▶ Proje hedefleri ve gereksinimleri, iş birimi ya da araştırma biriminin bütünsel ihtiyaçları doğrultusunda belirlenir.
- ▶ Bu hedef ve kısıtlar, bir veri madenciliği problemi tanımına dönüştürülür.
- ▶ Son olarak, bu hedeflere ulaşmak için ön strateji hazırlanır.

2. Veriyi Anlama adımı

- ▶ İlk olarak, veri toplanır.
- ▶ Keşifsel veri analizi yöntemleri ile veriye aşinalık kazanılır ve ilk içgörüler elde edilir.
- ▶ Verinin kalitesi değerlendirilir.
- ▶ Gerekmesi durumunda veriden anlamlı desenler içerebilecek gruplar seçilir.

CRISP-DM Adımları (Devam)

3. Veri Hazırlama

- ▶ Bu aşamada, ham veriye gerekli işlemlerin uygulanmasıyla veri setinin hazırlanır ve daha sonra kullanılacak modelleme araçlarına uygun hale getirilir.
- ▶ Analiz edilecek uygun gözlemler ve değişkenler seçilir.
- ▶ Kayıp gözlemlerle ilgilenilir.
- ▶ Gerekli olması durumunda bazı değişkenlere dönüşümler uygulanır.

4. Modelleme adımı

- ▶ Uygun modelleme teknikleri seçilir ve uygulanır.
- ▶ Model parametreleri sonuçları optimize edecek şekilde ayarlanır.
- ▶ Bazı modelleme yöntemleri farklı veri formatları gerektiğinden veri hazırlama adımına geri dönmek gerekebilir.

CRISP-DM Adımları (Devam)

5. Değerlendirme

- ▶ Modelleme aşamasında elde edilen modellerin kalitesi ve etkinliği değerlendirilir.
- ▶ Modelin, birinci aşamada belirlenen hedefleri ne derece gerçekleştirdiği kontrol edilir.
- ▶ İş veya araştırma probleminin önemli bir yönünün gözden kaçırılıp kaçırılmadığı belirlenir.
- ▶ Son olarak, veri madenciliği sonuçlarının kullanımı konusunda karar verilir.

6. Uygulama

- ▶ Uygun modelleme teknikleri seçilir ve uygulanır.
- ▶ Model parametreleri sonuçları optimize edecek şekilde ayarlanır.
- ▶ Bazı modelleme yöntemleri farklı veri formatları gerektiğinden veri hazırlama adımına geri dönmek gerekebilir.

Veri Madenciliğinin Kullanım Amaçları

1. Birliktelik analizi
2. Kestirim amaçlı analizlerde sınıflama ve regresyon
3. Kümeleme analizi
4. Sapan değer analizi

Birliktelik analizi

- ▶ Veri kümesinde birlikte sık tekrar eden öğelerin belirlenmesinde kullanılır.
- ▶ **Örnek:** Bir e-ticaret mağaza yöneticisi, hangi ürünlerin aynı alışverişte sıkça birlikte satın alındığını öğrenmek istemektedir. İncelenen alışveriş verilerinden aşağıdaki birliktelik kuralı elde edilmiştir.

$$\text{buys}(X, \text{"bilg."}) \Rightarrow \text{buys}(X, \text{"webcam"})[\text{destek} = \%1, \text{guven} = \%50]$$

Bu elde edilen kurala göre, bilgisayar alan bir müşterinin %50 güven ile webcam alacağını, destek ise tüm alışverişlerin %1'inde bilgisayar ve webcam'in birlikte alındığını göstermektedir.

- ▶ Asgari bir destek eşliğini ve de güven eşliğini karşılamayan ilişki kuralları ile genellikle ilgilenilmez.

Birliktelik analizi (kaggle örneği)

Birliktelik analizi içeren bir kaggle verisi örneği aşağıdaki linkten ulaşılabilir.
<https://www.kaggle.com/code/seokhyokang/r-grocery-store-association-rules-analysis/notebook>

Sınıflama ve Regresyon Analizleri

- ▶ Sınıflama analizi, önceden sınıfları bilineni veri kümelerini kullanarak bir model oluşturur ve bu modeli yeni, sınıfları bilinmeyen verileri sınıflara atamak için kullanır.
- ▶ Örnek: e-postaları “spam” veya “spam değil” olarak sınıflandırmak
- ▶ Örnek: müşterileri “kredi riski yüksek” veya “kredi riski düşük” olarak ayırmak.
- ▶ Sınıflama kategorik değerleri tahmin etmede kullanılırken regresyon nümerik değerlerin tahmininde kullanılır.

Örnek: Sınıflandırma

Bir e-ticaret mağazası satış yöneticisi, mağazadaki ürünleri, bir satış kampanyasına verilen tepkilere göre sınıflandırmak istemektedir.

Tepki Sınıfları:

- ▶ İyi Tepki
- ▶ Orta Tepki
- ▶ Tepki Yok

Amaç: Ürünlerin fiyat, marka, üretim yeri, tür ve kategori gibi tanımlayıcı özelliklerini kullanarak her bir tepki sınıfını kestirebilen bir model oluşturmak.

Örnek: Regresyon

- ▶ Bu kez, her ürün için kategorik tepki sınıflarını tahmin etmek yerine önümüzdeki indirim döneminde her ürünün ne kadar **gelir** getireceğini tahmin etmek istiyorsunuz.

Neden Regresyon?

- ▶ Nümerik yani sürekli bir değer olan gelir miktarını tahmin etmek istiyoruz.
- ▶ Model, geçmiş satış verilerine dayanarak bir satılam istenecek yeni bir ürünün getirebileceği geliri kestirebilecektir.

Sınıflama analizi örneği (Kaggle)

<https://www.kaggle.com/code/mrisdal/exploring-survival-on-the-titanic>

Kümeleme Analizi

- ▶ Sınıflandırma , sınıf değişkenleri bilinen veri kümelerini gruplar iken kümeleme analizi sınıf değerleri bilinmeyen veri nesnelerini gruplar.
- ▶ Örnek: Bir e-ticaret mağazasının müşteri verisi üzerinde kümeleme analizi yapılır.
- ▶ Amaç: benzer özelliklere sahip alt müşteri gruplarını belirlemektir.
- ▶ Bu kümeler, hedeflenmiş pazarlama kampanyaları için kullanılabilir.

Kümeleme analizi örneği (Kaggle)

<https://www.kaggle.com/code/marklondon79/cluster-analysis-in-r>

Aykırı (Sapan) değer analizi

- ▶ Veri kümesinde, genel davranışa veya modele uymayan nesnelerdir.
- ▶ Çoğu veri madenciliği yöntemi, aykırı değerleri **gürültü** veya istisna olarak görüp eler.
- ▶ Ancak bazı uygulamalarda (ör: dolandırıcılık tespiti) nadir olaylar, sık görülenlerden daha ilginç olabilir.

Aykırı Değer Tespiti Yöntemleri:

- ▶ İstatistiksel Testler: Veri dağılımı varsayımı ile çalışır.
- ▶ Uzaklık Tabanlı: Küme merkezlerinden uzak olan nesneler aykırı kabul edilir.
- ▶ Yoğunluk Tabanlı: Yerel yoğunluk farklılıklarına odaklanır.

Veri madenciliği yanılgıları

1. Veri madenciliği insan müdahalesine ihtiyaç duymaz.
2. Veri madenciliği yazılımlarını yükleyip hemen kullanabiliriz.
3. Veri madenciliği, iş veya araştırma problemlerimizin nedenlerini ortaya çıkarır.
4. Veri madenciliği, yıllardır kullanılmamış ve bakımsız kalmış verileri otomatik olarak temizler.
5. Veri madenciliği her zaman işe yarar ve pozitif sonuçlar sağlar.

Gelecek ders

- ▶ Veri ön işleme
- ▶ R, Rstudio ve kullanılacak kütüphanelerin tanıtımı