

ISB206 Veri Madenciliği

3. Ders: Sınıflama Analizi

25.02.2026

Veri madenciliği yöntemleri

Veri madenciliği yöntemleri iki temel grup altında incelenmektedir. Bunlar

Gözetimli Öğrenme

Gözlemlerin karşılık gelen yanıt (sınıf) değişkenlerin bulunduğu veri setleriyle çalışır. Model, bu örneklerden öğrenerek yeni veriler için tahminlerde bulunmayı amaçlar. Örneğin, bir e-posta sınıflandırma modeli, daha önce "spam" ve "spam değil" olarak etiketlenmiş e-postalar üzerinde eğitilir.

Gözetimsiz Öğrenme

Veri setinde yanıt değişkeni bulunmaz. Model, veriler arasındaki yapıları ve ilişkileri keşfetmeye çalışır. Bu yöntemlerle, müşteri ayrıştırma için bir model oluşturabilir veya benzer alışveriş alışkanlıklarına sahip kullanıcıları gruplandırabilir.

Gözetimli vs Gözetimsiz öğrenme

- ▶ Gözetimli öğrenme:
 - ▶ **Sınıflama analizi**
 - ▶ Regresyon analizi
- ▶ Gözetimsiz öğrenme:
 - ▶ İlişki kuralları
 - ▶ Kümeleme analizi
 - ▶ Boyut indirgeme

Gözetimli vs Gözetimsiz öğrenme

- ▶ Gözetimli öğrenme:
 - ▶ **Sınıflama analizi**
 - ▶ Regresyon analizi
- ▶ Gözetimsiz öğrenme:
 - ▶ İlişki kuralları
 - ▶ Kümeleme analizi
 - ▶ Boyut indirgeme

Sınıflama analiz

Makine öğrenmesinde sınıflama, bir gözlemi önceden tanımlanmış belirli kategorilerden birine atama işlemidir. Temelde bir "tahminleme" yöntemidir ancak burada tahmin edilen şey bir sayı değil, bir gruptur.


Sınıflama yöntemleri

- ▶ K en yakın komşuluk (KNN)
- ▶ Karar ağaçları
- ▶ Yapay sinir ağları
- ▶ Lojistik regresyon
- ▶ Destek vektör makineleri


K en yakın komşuluk algoritması

- ▶ En sık kullanılan sınıflama yöntemlerinden biridir.
- ▶ Bir tembel öğrenme yöntemidir (Bir model oluşturulmaz).
- ▶ Sezgisel olarak kolaylıkla anlaşılabilir.
- ▶ Çalışma prensibi:
 - ▶ Bir k sayısı belirlenir.
 - ▶ Yeni bir gözlemin yanıt değişkeni, en yakın k komşusunun en sık görülen yanıt değeri olarak atanır.


Örnek: Na/K, yaş ve uygulanan ilaç verisi




Örnek: Bu veri kümesine üç yeni gözlem ekleyelim. Yeni gözlemler hangi ilaçları kullanmalı?




Örnek: $k = 1$ için KNN sonucu.



Örnek:k=2 için sonuçlar değişir mi?



Örnek:k=3 için sonuçlar değişir mi?



Bu örnek sayesinde KNN uygulamadan karar verilmesi gereken bazı tercihleri göstermiştir. Bunlar:

- ▶ İki gözlem arasındaki uzaklık nasıl belirlenmeli?
- ▶ Birden fazla gözlemden alınan bilgi nasıl birleştirilmeli?
- ▶ k ne seçilmeli?
- ▶ Tüm gözlemler eşit mi ağırlıklanmalı?

Uzaklık fonksiyonları

Uzaklık fonksiyonu, x ve y iki gözlem olmak üzere aşağıdaki üç özelliği sağlaması beklenir.

1. $d(x, y) \geq 0$ ve $d(x, y) = 0$ ancak ve ancak $x = y$
2. $d(x, y) = d(y, x)$
3. $d(x, z) \leq d(x, y) + d(y, z)$

- Nümerik değişkenler için öklidyen uzaklık kullanılır:

$$d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}, i = 1, 2, \dots, m$$

Burada m açıklayıcı değişken sayısıdır.

- Kategorik değişkenler için uzaklık tanımlanamaz. Bu nedenle bir farklılık ölçüsü kullanılmalı. En çok kullanılan farklılık fonksiyonu:

$$fark(x_i, y_i) = \begin{cases} 0 & \text{eğer } x = y \\ 1 & \text{eğer } x \neq y \end{cases}$$

Buradan elde edilen değer (0 ya da 1) uzaklık fonksiyonunda karşılık gelen $x_i - y_i$ yerine yazılmalıdır.

- Not: Açıklayıcı değişkenler kategorik değişken içeriyor veya nümerik değişkenler birbirlerinden farklı büyüklüklerde ise uzaklıklar hesaplanmadan önce nümerik değişkenlere min-maks dönüşümü uygulamak gerekmektedir.

Üç gözlem arasındaki uzaklık

Hasta	Yaş	$Yaş_{MM}$	Cinsiyet
A	50	$\frac{50-10}{60-10} = 0.8$	E
B	20	$\frac{20-10}{60-10} = 0.2$	E
C	50	$\frac{50-10}{60-10} = 0.8$	K

Tablo: Yaş ve cinsiyet verisinden üç gözlem (maksimum yaşı 60 ve minimum yaşı 10 olduğu biliniyor).

- ▶ $d(A, B) = \sqrt{(0.8 - 0.2)^2 + 0^2} = 0.6$
- ▶ $d(A, C) = \sqrt{(0.8 - 0.8)^2 + 1^2} = 1$
- ▶ $d(B, C) = \sqrt{(0.2 - 0.8)^2 + 1^2} = \sqrt{1.36}$

Üç gözlem arasındaki uzaklık

Hasta	Yaş	$Yaş_{MM}$	Cinsiyet
A	50	$\frac{50-10}{60-10} = 0.8$	E
B	20	$\frac{20-10}{60-10} = 0.2$	E
C	50	$\frac{50-10}{60-10} = 0.8$	K

Tablo: Yaş ve cinsiyet verisinden üç gözlem (maksimum yaşı 60 ve minimum yaşı 10 olduğu biliniyor).

- ▶ $d(A, B) = \sqrt{(0.8 - 0.2)^2 + 0^2} = 0.6$
- ▶ $d(A, C) = \sqrt{(0.8 - 0.8)^2 + 1^2} = 1$
- ▶ $d(B, C) = \sqrt{(0.2 - 0.8)^2 + 1^2} = \sqrt{1.36}$
- ▶ Bu sonuca göre birbirlerine en benzeyen hastalar A ve B hastaları iken en az benzeyenler B ve C hastalarıdır.

Üç gözlem arasındaki uzaklık

Hasta	Yaş	$Yaş_{MM}$	Cinsiyet
A	50	$\frac{50-10}{60-10} = 0.8$	E
B	20	$\frac{20-10}{60-10} = 0.2$	E
C	50	$\frac{50-10}{60-10} = 0.8$	K

Tablo: Yaş ve cinsiyet verisinden üç gözlem (maksimum yaşı 60 ve minimum yaşı 10 olduğu biliniyor).

- ▶ $d(A, B) = \sqrt{(0.8 - 0.2)^2 + 0^2} = 0.6$
- ▶ $d(A, C) = \sqrt{(0.8 - 0.8)^2 + 1^2} = 1$
- ▶ $d(B, C) = \sqrt{(0.2 - 0.8)^2 + 1^2} = \sqrt{1.36}$
- ▶ Bu sonuca göre birbirlerine en benzeyen hastalar A ve B hastaları iken en az benzeyenler B ve C hastalarıdır.
- ▶ Not:Min-Maks dönüşümü kullanılmasaydı sonuçlar nasıl etkilenirdi?

Yeni gözlem için sınıf değişkeninin atanması

- ▶ Artık gözlemler arasındaki uzaklıkları belirleyebildiğimize göre, sınıf değerini bilmediğimiz yeni bir gözlemin k adet en yakın komşusunu belirleyebiliriz.

Yeni gözlem için sınıf değişkeninin atanması

- ▶ Artık gözlemler arasındaki uzaklıkları belirleyebildiğimize göre, sınıf değerini bilmediğimiz yeni bir gözlemin k adet en yakın komşusunu belirleyebiliriz.
- ▶ Peki belirlediğimiz komşularla yeni gözlemin sınıf değerini nasıl belirlemeliyiz?

Yeni gözlem için sınıf değişkeninin atanması

- ▶ Artık gözlemler arasındaki uzaklıkları belirleyebildiğimize göre, sınıf değerini bilmediğimiz yeni bir gözlemin k adet en yakın komşusunu belirleyebiliriz.
- ▶ Peki belirlediğimiz komşularla yeni gözlemin sınıf değerini nasıl belirlemeliyiz?
- ▶ Bu amaçla iki temel yöntem kullanılmaktadır. Bunlar, basit oylama ve ağırlıklı oylama.

Oylama yöntemleri

Basit oylama

- ▶ Yeni bir gözlemin sınıf değeri, k komşularının çoğunluk sınıf değeridir.
- ▶ Komşuların gözleme olan uzaklıklarından etkilenmez.
- ▶ Bazı durumlarda k komşu için her sınıf eşit sayıda oy alabilir (Örnek için bkz. Şekil 1. $k = 2$ durumu).

Ağırlıklı oylama:

- ▶ Bu yöntemde yeni gözleme daha yakın komşuların oyları daha fazla ağırlıklandırılır.
- ▶ Bir komşunun yeni gözlemin sınıfına olan etkisi aralarındaki uzaklıkla ters orantılıdır.

Örnek: Ağırlıklı oylama

Sıra	İlaç(Sınıf)	Yaş	Na/K	Age_{MM}	Na/K_{MM}
Yeni		17	12.5	0.05	0.25
12.	A ilacı	16.8	12.4	0.0467	0.2471
37.	B ilacı	17.2	10.5	0.0533	0.1912
65.	B ilacı	19.5	13.5	0.0917	0.2794

- ▶ Tablo'da Şekil 1.'de verilen örnek için 1. gözlem yeni bir gözlemi göstermekte ve kalanlar bu gözlemin $k = 3$ için belirlenen en yakın komşularıdır.
- ▶ Yeni gözlemin hangi ilacı kullanacağını basit oylama ile belirlemek istersek komşuların çoğunluğu B ilacı sınıf değişkenine sahip olduğu için yeni gözlem için de sınıf değişkeni B ilacı olarak atanır.

Örnek: Ağırlıklı oylama (Devam)

- ▶ Aynı örnek için sınıf değişkeni ağırlıklı oylama ile belirleyelim.
- ▶ Ağırlıklı oylama için yeni gözlem ile diğer gözlemler arasındaki uzaklıklar:
 - ▶ $d(yeni, 12) = \sqrt{(0.05 - 0.0467)^2 + (0.25 - 0.2471)^2} = 0.004393$
 - ▶ $d(yeni, 37) = \sqrt{(0.05 - 0.0533)^2 + (0.25 - 0.1912)^2} = 0.058893$
 - ▶ $d(yeni, 65) = \sqrt{(0.05 - 0.0917)^2 + (0.25 - 0.2794)^2} = 0.051022$
- ▶ Buradan A ilacı için oylar: $1/d(new, 12)^2 = 1/(0.004393)^2 \simeq 51818$
- ▶ B ilacı için oylar:
 $1/d(new, 37)^2 + 1/d(new, 65)^2 = 1/(0.059)^2 + 1/(0.051)^2 \simeq 672$
- ▶ A'nın oyları, B'nin oylarından fazla olduğu için ağırlıklı oylama 17 yaşında, Na/K oranı 12.5 olan bir hastaya **A ilacı**'nı önermektedir.

k 'nın seçimi

- ▶ Çok küçük seçilen k değeri sınıflama sonucunun aykırı değerlere karşı kötü performans gösterebilmesine neden olabilmektedir.
- ▶ Çok büyük seçilen k değeri ise veri içindeki kullanışlı, yerel bölgeleri kullanılmamasına sebep olabilmektedir.
- ▶ Bu nedenle genellikle k değerinin ne çok az ne de çok fazla bir değer olarak belirlenmemesi gerekmektedir.
- ▶ Ayrıca, en iyi k değeri, farklı k değerleriyle sınıflama yapıldıktan sonra, ileride göreceğimiz performans ölçüm yöntemleri ile karşılaştırılarak belirlenebilir.

R uygulaması (Loan data)

```
> library(class) # knn fonksiyonu bu pakette # Paket yüklü değil ise  
# install.packages("class")
```

R uygulaması (Devam)

```
> class<-df[1:6500,12] # sınıf değişkeni atandı  
> dftrain<-df[1:6500,-12] # İlk 6500 gözlem eğitim verisi yapıldı  
> dftest<-df[6501:7000,-12] # son 500 gözlem test verisi yapıldı
```

R uygulaması (Devam)

```
> dftrain<-apply(dftrain,2,minMax) # minMax fonksiyonu verinin tüm  
                                     # sütunlarına uygulanıyor  
> dftest<-apply(dftest,2,minMax) # minMax fonksiyonu verinin tüm  
                                   # sütunlarına uygulanıyor
```

R uygulaması (Devam)

```
> dftrain<-apply(dftrain,2,minMax) # minMax fonksiyonu verinin tüm
                                     # sütunlarına uygulanıyor
> dftest<-apply(dftest,2,minMax) # minMax fonksiyonu verinin tüm
                                   # sütunlarına uygulanıyor
> knn_sonuc<-knn(train=dftrain,test=dftest,cl=class,k=5) # k=5 için knn
                                                         # uygular
> knn_sonuc                                     # test verileri için sınıf tahminleri
```