

ISB206 Veri Madenciliği

5. Ders: Sınıflama yöntemleri için performans ölçüleri

11.03.2026

İçindekiler

- 1 Giriş
- 2 Veri Bölümleme
- 3 Karmaşıklık Matrisi
- 4 Temel Metrikler

Eğitim-Test Ayrımı

- ▶ Denetimli öğrenme yöntemleri uygulanmadan önce veri kümesinin eğitim ve test verisi olarak ikiye ayrılması gerekmektedir. Genellikle veri kümesinin elemanlarından rasgele %80'i eğitim verisi %20'si test verisi olarak ayrılır.
- ▶ Yöntem (ya da model) girdisi olarak yalnızca eğitim verisi kullanılır ve model bu veri üzerinde eğitilir.
- ▶ Geliştirilen model test verisinde yanıt(hedef) değişken tahmin edilir.
- ▶ Daha sonra test verisindeki gerçek yanıt değişkenleri ile tahmin edilen yanıt değişkenleri karşılaştırılarak çeşitli model performans ölçümleri elde edilebilir.
- ▶ Model parameterelerini belirlenmesinde de bu ölçülerden faydalanılabilir. (Örneğin, KNN için k parametresinin belirlenmesi)
- ▶ Ayrıca verinin eğitim ve test şeklinde ayrılması, elde edilen modellerin veriye aşırı uyumlu (overfitting) olmasını engeller.

Aşırı uyum

Modelin, eğitim verisindeki genel örüntüleri öğrenmek yerine, verideki rastgele gürültüyü (noise) ve istisnaları gerçek bir ilişkiymiş gibi modellemesi durumudur.


Temel Belirtiler:

- ▶ Eğitim setinde kusursuz veya çok yüksek doğruluk.
- ▶ Test setinde beklenmedik düşük performans.
- ▶ Yüksek Varyans: Model, verideki küçük değişimlere aşırı duyarlıdır.

Nedenleri:

- ▶ Modelin veri setine kıyasla çok karmaşık olması.
- ▶ Eğitim verisinin yetersiz olması.
- ▶ Gereksiz fazla öznitelik kullanımı.

Aşırı uyumluluk problemi



Karmaşıklık Matrisi (Confusion Matrix)

- ▶ TP (True positive): 1 olarak tahmin edilen bir sınıfın gerçekte de 1 olması
- ▶ TN (True negative): 0 olarak tahmin edilen bir sınıfın gerçekte de 0 olması
- ▶ FN (False negative): 1 olarak tahmin edilen bir sınıfın gerçekte 0 olması
- ▶ FP (False positive): 0 olarak tahmin edilen bir sınıfın gerçekte 1 olması

Örnek bir veri için elde edilen 2x2'lik karmaşıklık matrisi

Tahmin	Gerçek	
	0	1
0	424 (TN)	20 (FN)
1	53 (FP)	53 (TP)

Performans Metrikleri

- ▶ Doğruluk (Accuracy): Olumlu veya olumsuz olması fark etmeksizin doğru olan tüm sınıflandırmaların oranıdır.

$$\frac{TP + TN}{TP + TN + FP + FN}$$

- ▶ Kesinlik(Precision), modelin tüm pozitif sınıflandırmalarının gerçekte pozitif olan kısmının oranıdır.

$$\frac{TP}{TP + FP}$$

- ▶ Duyarlılık (Recall) doğru olarak pozitif olarak sınıflandırılan tüm gerçek pozitiflerin oranı, geri çağırma olarak da bilinir

$$\frac{TP}{TP + FN}$$

- ▶ F1-Skoru: Kesinlik ve duyarlılığı tek ölçüde harmonik ortalamasıdır.

$$2 \times \frac{\text{Kesinlik} \times \text{Duyarlılık}}{\text{Kesinlik} + \text{Duyarlılık}}$$

Hangi metrik ne zaman kullanılmalı

- ▶ Doğruluk: Modelin uygunluğu hakkında genel fikir almada kullanılabilir. Özellikle sınıf değerlerinin dengeli olmadığı durumlarda kullanımdan kaçınılmalıdır.Örneğin: Gözlemlerden %90'ının spam maillerden oluşan bir veri kümesi.
- ▶ Kesinlik: FP sayısı FN sayısından daha önemli ise kullanılmalıdır.
- ▶ Duyarlılık: FN sayısı FP sayısından daha önemli ise kullanılmalıdır.

Hangi metrik ne zaman kullanılmalı


- ▶ Doğruluk: Modelin uygunluğu hakkında genel fikir almada kullanılabilir. Özellikle sınıf değerlerinin dengeli olmadığı durumlarda kullanımdan kaçınılmalıdır.Örneğin: Gözlemlerden %90'ının spam maillerden oluşan bir veri kümesi.
- ▶ Kesinlik: FP sayısı FN sayısından daha önemli ise kullanılmalıdır.
- ▶ Duyarlılık: FN sayısı FP sayısından daha önemli ise kullanılmalıdır.
- ▶ Not: Burada verilen tüm metrik değerleri için elde edilen değer arttıkça model performansı artmaktadır.

ROC eğrisi

- ▶ Alıcı İşletim Karakteristiği (ROC) eğrisi model performansının görselleştirilmesinde kullanılır.
- ▶ ROC eğrisi y-ekseninde TPR(True positive oranı) ve x-ekseninde FNR (False negative oranı) farklı eşik değerler için hesaplanıp işaretlenmesi ile oluşturulur.
- ▶ Eğri altındaki alanı (AUC) daha büyük olan model daha iyi model gösterir.
- ▶ Not: Burada, $TPR = \frac{TP}{TP+FN}$ ve $FPR = \frac{FP}{FP+TN}$.

AUC değeri	Model yetkinliği
0.9-1.0	Kuvvetli ayırt edici
0.8-0.9	Kullanılabilir performans
0.7-0.8	Sınırlı başarı
0.5-0.7	Rastgele tahmine yakın

ROC örneği



R örneği

```
>library(class) # knn fonksiyonu bu pakette
>library(caret) # Sınıflama metrikleri bu pakette
>library(MLevel) # ROC curve için
##Verinin yüklenmesi
>df<-read.csv("loan.csv")
>df<-df[,-(1:3)] İlk üç sütun veriden çıkarılıyor

# Min-Maks normalizasyonu için fonksiyon tanımlama
> minMax <- function(x) {
(x - min(x)) / (max(x) - min(x))
}
```

```
> dim(df)
# toplam gözlem sayısı 7000
> 7000*.8
# 5600 kişi eğitim verisi kalanlar test verisi olarak ayarlanacak

> df<-sample(df)  Tüm gözlemlerin sıralamasını rasgele olarak değiştirir
> class<-df[1:5600,12] # sınıf değişkeni
> class_test<-df[5601:7000,12] # test verisi için sınıf değişkeni
> dftrain<-df[1:5600,-12] # ilk 5600 gözlem eğitim verisi
> dftest<-df[5601:7000,-12] # son son 1400 gözlem veri test verisi
yapıldı
> dftrain<-apply(dftrain,2,minMax) ## minMax fonksiyonu eğitim verisinin
tüm değişkenlerine uygulanıyor
> dfest<-apply(dfest,2,minMax) ## minMax fonksiyonu test verisinin tüm
değişkenlerine uygulanıyor
```

Farklı k değerleri ile knn sonuçları

```
>knn_sonuc3<-knn(train=dftrain,test=dftest,cl=class,k=3)
>knn_sonuc5<-knn(train=dftrain,test=dftest,cl=class,k=5)
>knn_sonuc10<-knn(train=dftrain,test=dftest,cl=class,k=10)
>knn_sonuc35<-knn(train=dftrain,test=dftest,cl=class,k=35)
```

Sınıflama metrikleri

```
>confusionMatrix(data = knn_sonuc3,reference =
as.factor(class_test))
>confusionMatrix(data = knn_sonuc5,reference =
as.factor(class_test))
>confusionMatrix(data = knn_sonuc10,reference =
as.factor(class_test))
>confusionMatrix(data = knn_sonuc35,reference =
as.factor(class_test))
```

```
# ROC eğrisi
# Farklı k değerleri ile knn sonuçları, sonuçlar olasılık olarak
verildi
p_knn_sonuc3<-knn(train=dftrain,test=dftest,cl=class,k=3,prob =
T)
p_knn_sonuc5<-knn(train=dftrain,test=dftest,cl=class,k=5,prob =
T)
p_knn_sonuc10<-knn(train=dftrain,test=dftest,cl=class,k=10,prob =
T)
p_knn_sonuc35<-knn(train=dftrain,test=dftest,cl=class,k=35,prob =
T)

library(smallstuff) ## knn grafikleri için
par(mfrow=c(2,2)) ## grafik alanını 2x2 lik hale dönüştürür
ROCknn(p_knn_sonuc3,class_test)
ROCknn(p_knn_sonuc5,class_test)
ROCknn(p_knn_sonuc10,class_test)
ROCknn(p_knn_sonuc35,class_test)
par(mfrow=c(1,1)) ## grafik alanını tekrar tek parça yapar
```

Ödev

```
## 2. veri Winsconsin Breast Cancer Data  
library(mlbench)  
data("BreastCancer")  
df<-BreastCancer  
head(df)  
df<-df[,-1]  
dim(df)
```