

ISB206 Veri Madenciliği

6. Ders: Naive Bayes Sınıflama

25.03.2026

Bayes sınıflandırıcılar

- ▶ Bayes sınıflandırıcılar, bir gözlem grubunun bir sınıfa ait olma olasılığını Bayes teorimi kullanarak tahmin edebilirler.
- ▶ Genel form: $C_1, C_2, \dots, C_m$ şeklinde m adet sınıfımız olsun. Verilen bir $\mathbf{X} = (X_1, X_2, \dots, X_p)$ veri grubu için, bu verinin hangi sınıfa ait olduğunu tahmin etmek isteriz.
- ▶ Bayesyen sınıflandırıcıda, önce her bir sınıf için sonsal (posterior) olasılıklar olan $P(C_i|\mathbf{X})$, $i = 1, \dots, m$ değerleri hesaplanır. Daha sonra hesaplanan olasılıklar karşılaştırılır ve en büyük $P(C_i|\mathbf{X})$ olasılığını veren C_i sınıfı $\mathbf{X}$ grubunun sınıf tahmini olarak elde edilir.

Bayes sınıflandırıcılar

- İlgili olasılık Bayes teoremi ile aşağıdaki gibi hesaplanabilir.

$$P(C_i|\mathbf{X}) = \frac{P(\mathbf{X}|C_i)P(C_i)}{P(\mathbf{X})}$$

- Amacımız tüm sınıfların olasılıklarını birbiriyle kıyaslamak olduğu için sabit olan paydayı ihmal edebiliriz. Yani:

$$P(C_i|\mathbf{X}) \propto P(\mathbf{X}|C_i)P(C_i)$$

- Burada $P(\mathbf{X}|C_i)$ olasılığının hesaplamak genel olarak zordur. Bu zorluğun en basit çözümü olarak Naive Bayes algoritması önerilmiştir.

Naive Bayes

- Değişkenlerin birbirinden bağımsız ve eşit önemde olduğu kabul edilir. Yani

$$P(\mathbf{X}|C_i) = P(X_1 = x_1|C_i)P(X_2 = x_2|C_i) \dots P(X_p = x_p|C_i)$$

- Burada $P(X_k = x_k|C_i)$ olasılığı k -ıncı değişken kategorik ise C_i sınıfında olan verilerin x_k değeri alanların sayısının toplam C_i sınıfına sahip gözlem sayısına oranı ile elde edilir. Yani:

$$P(X_k = x_k|C_i) = \frac{|X_k = x_k \cap C_i|}{|C_i|}$$

- k -ıncı değişken nümerik ise değişken için normal dağılım gibi bir dağılım varsayımında bulunulur. Örneğin

$$f(x_k|C_i) = \frac{1}{\sqrt{2\pi}} \exp \left\{ \left(\frac{x_k - \mu_{C_i}}{\sigma_{C_i}} \right)^2 \right\}$$

burada, μ_{C_i} ve σ_{C_i} sırasıyla C_i sınıfına ait gözlemlerde X_k 'nın ortalama ve varyansını gösterir.

Naive Bayesin Özellikleri

- ▶ $P(X_k = x_k | C_i)$ olasılığını hesaplayan daha doğru ve daha az varsayımli yöntemler de olmasına rağmen basitliği nedeniyle en bilinen Bayes sınıflandırıcılarından biridir.
- ▶ Gürültülü, kayıp gözlem içeren ve çok sayıda değişken gibi problemelerle de iyi çalışır.
- ▶ Sadece sınıf değeri değil sınıfa ait olma olasılığı da hesaplar

Naive Bayes için Varsayımlar ve Önemi

- ▶ **Naive Bayes varsayımları:** Değişkenlerin birbirinden bağımsız ve eşit önemde olduğu kabul edilir; bu varsayımlar çoğu uygulamada geçerli değildir.
- ▶ Değişkenler arasında güçlü bağımlılıklar olsa dahi (varsayımlar ihlal edilse dahi) Naive Bayes genellikle iyi performans gösterir.
- ▶ **Küçük veri kümelerinde avantaj:** Az sayıda eğitim verisiyle bile etkili çalışabildiği için sınıflandırma görevlerinde genellikle makul bir başlangıç modeli olarak tercih edilir.

Örnek:

Tablo: Bir elektronik mağazasının müşteri veritabanından sınıf etiketli eğitim örnekleri. Sınıf değişkenin kişinin bilgisayar alıp almadığını gösterir.

RID	Yaş(X_1)	Gelir(X_2)	Öğrenci(X_3)	Kredi Notu(X_4)	Sınıf (C)
1	genç	yüksek	hayır	iyi	hayır
2	genç	yüksek	hayır	mükemmel	hayır
3	orta yaşlı	yüksek	hayır	iyi	evet
4	yaşlı	orta	hayır	iyi	evet
5	yaşlı	düşük	evet	iyi	evet
6	yaşlı	düşük	evet	mükemmel	hayır
7	orta yaşlı	düşük	evet	mükemmel	evet
8	genç	orta	hayır	iyi	hayır
9	genç	düşük	evet	iyi	evet
10	yaşlı	orta	evet	iyi	evet
11	genç	orta	evet	mükemmel	evet
12	orta yaşlı	orta	hayır	mükemmel	evet
13	orta yaşlı	yüksek	evet	iyi	evet
14	yaşlı	orta	hayır	mükemmel	hayır

Örnek:(devam)

- Mağazaya gelen genç, orta düzey gelirli, öğrenci ve kredi notu iyi olan birinin bilgisayar alıp alamayacağını kestirelim. Bunun için,

$$\mathbf{X} = (\text{yaş=genç, gelir=orta, öğrenci=evet, krediskoru=iyi})$$

olmak üzere $P(C = \text{Evet}|\mathbf{X})$ ve $P(C = \text{Hayır}|\mathbf{X})$ olasılıklarını hesaplayıp karşılaştırmalıyız.

Örnek:(devam)

- ▶ Mağazaya gelen genç, orta düzey gelirli, öğrenci ve kredi notu iyi olan birinin bilgisayar alıp alamayacağını kestirelim. Bunun için,

$$\mathbf{X} = (\text{yaş=genç, gelir=orta, öğrenci=evet, krediskoru=iyi})$$

olmak üzere $P(C = \text{Evet}|\mathbf{X})$ ve $P(C = \text{Hayır}|\mathbf{X})$ olasılıklarını hesaplayıp karşılaştırmalıyız.

- ▶ Bu olasılıkları Bayes formülü kullanarak

$$P(C = \text{Evet}|\mathbf{X}) = \frac{P(\mathbf{X}|C = \text{Evet})P(C = \text{Evet})}{P(\mathbf{X})} \propto P(\mathbf{X}|C = \text{Evet})P(C = \text{Evet})$$

$$P(C = \text{Hayır}|\mathbf{X}) = \frac{P(\mathbf{X}|C = \text{Hayır})P(C = \text{Hayır})}{P(\mathbf{X})} \propto P(\mathbf{X}|C = \text{Hayır})P(C = \text{Hayır})$$

şeklinde yazabiliriz. Burada elde edilen olasılıklar karşılaştırılacağı için paydadaki $P(\mathbf{X})$ 'in hesaplanması gerekmez.

Örnek:(devam)

- ▶ Ayrıca naive Bayes yönteminde değişkenlerin bağımsız olduğu varsayıldığı için olasılıklar

$$P(\mathbf{X}|C = \text{Evet}) = P(X_1 = \text{genç}|C = \text{Evet})P(X_2 = \text{orta}|C = \text{Evet}) \\ P(X_3 = \text{evet}|C = \text{Evet})P(X_4 = \text{iyi}|C = \text{Evet})$$

ve

$$P(\mathbf{X}|C = \text{Hayır}) = P(X_1 = \text{genç}|C = \text{Hayır})P(X_2 = \text{orta}|C = \text{Hayır}) \\ P(X_3 = \text{evet}|C = \text{Hayır})P(X_4 = \text{iyi}|C = \text{Hayır})$$

Örnek:(devam)

- Buna göre gerekli olasılıklar veriden aşağıdaki gibi elde edilir.

$C = \text{Evet}$	$C = \text{Hayır}$
$P(C = \text{Evet}) = 9/14$	$P(C = \text{Hayır}) = 5/14$
$P(X_1 = \text{genç} C = \text{Evet}) = 2/9$	$P(X_1 = \text{genç} C = \text{Hayır}) = 3/5$
$P(X_2 = \text{orta} C = \text{Evet}) = 4/9$	$P(X_2 = \text{orta} C = \text{Hayır}) = 2/5$
$P(X_3 = \text{evet} C = \text{Evet}) = 6/9$	$P(X_3 = \text{evet} C = \text{Hayır}) = 1/5$
$P(X_4 = \text{iyi} C = \text{Evet}) = 6/9$	$P(X_4 = \text{iyi} C = \text{Hayır}) = 2/5$

- Buradan

$$\begin{aligned} P(C = \text{Evet} | \mathbf{X}) &\propto P(\mathbf{X} | C = \text{Evet}) P(C = \text{Evet}) \\ &= \left(\frac{2}{9}\right) \left(\frac{4}{9}\right) \left(\frac{6}{9}\right) \left(\frac{6}{9}\right) \left(\frac{9}{14}\right) = 0.028 \end{aligned}$$

$$\begin{aligned} P(C = \text{Hayır} | \mathbf{X}) &\propto P(\mathbf{X} | C = \text{Hayır}) P(C = \text{Hayır}) \\ &= \left(\frac{3}{5}\right) \left(\frac{2}{5}\right) \left(\frac{1}{5}\right) \left(\frac{2}{5}\right) \left(\frac{5}{14}\right) = 0.007 \end{aligned}$$

Örnek:(devam)

- ▶ $P(C = \text{Evet}|\mathbf{X}) = 0.028 > P(C = \text{Hayır}|\mathbf{X}) = 0.007$ olduğundan naive Bayes yöntemi ilgilenilen $\mathbf{X}$ özelliklerine sahip kişinin bilgisayar alacağını tahmin eder.
- ▶ Burada elde edilen değerleri tam olasılıklara dönüştürmek için aşağıdaki gibi standartlaştırma yapılabilir.

$$P(C = \text{Evet}|\mathbf{X}) = \frac{0.28}{0.28 + 0.07} = 0.8$$

$$P(C = \text{Hayır}|\mathbf{X}) = \frac{0.07}{0.28 + 0.07} = 0.2$$

Alıştırma:

Aşağıdaki tablo, bazı e-postalara ait özellikleri ve bu e-postaların spam olup olmadığını göstermektedir. Burada X_1 ve X_2 değişkenleri e-postanın sırasıyla ücretsiz ve tıklayın kelimesini içerip içermediğini ve X_3 değişkeni ise e-postanın bir eki olup olmadığını göstermektedir. Buna göre Naive Bayes algoritması kullanarak, ücretsiz, ve tıklayın kelimeleri geçen ve ek içermeyen bir e-postanın spam olarak sınıflanıp sınıflanmadığını gösterin.

E-posta	Ücretsiz (X_1)	Tıklayın (X_2)	Ek (X_3)	Sınıf (C)
1	Evet	Evet	Hayır	Spam
2	Hayır	Hayır	Evet	Spam değil
3	Evet	Hayır	Hayır	Spam
4	Hayır	Evet	Hayır	Spam değil
5	Evet	Evet	Evet	Spam
6	Hayır	Hayır	Hayır	Spam değil
7	Evet	Hayır	Evet	Spam
8	Hayır	Evet	Evet	Spam değil
9	Evet	Evet	Hayır	Spam değil
10	Hayır	Hayır	Evet	Spam değil
11	Hayır	Hayır	Hayır	Spam
12	Hayır	Evet	Evet	Spam