

ISB206 Veri Madenciliği

8. Ders: Karar Ağaçları kullanarak sınıflama analizi

15.04.2026

Karar Ağaçları


Bu derste öğrenilecekler:

- ▶ Karar ağaçlarının verileri “açgözlü” bir şekilde sınıflara nasıl ayırdığını.
- ▶ En yaygın karar ağacı ve sınıflandırma algoritması C5.0'ın kullanımı.
- ▶ Bu algoritmanın riskli banka kredilerinin belirlemede nasıl kullanılabileceği.


Karar Ağaçları

- ▶ Karar ağacı yöntemleri, değişkenler ile olası sonuçlar arasındaki ilişkileri modellemek için ağaç yapısını kullanan güçlü sınıflandırıcılardır.
- ▶ Bu yöntemler adını elde edilen modelin gerçek bir ağaca benzemesinden alır.
- ▶ Bir diğer deyişle bir karar ağacı sınıflandırıcısı dallanarak ilerleyen kararlar aracılığıyla gözlemleri nihai tahmin değerlerine yönlendirir.
- ▶ Neredeyse her tür veriyi modellemek için kullanılabilirler ve çoğu zaman ayar yapılmadan dahi oldukça başarılı performans gösterirler.

Karar Ağacı Örneği (IRIS verisi)



Karar Ağacı Saçılım Grafiği Gösterimi



Karar Ağaçlarının Avantajları

- ▶ Akış şeması benzeri ağaç yapısının sadece makine tarafından değil, insanlar tarafından da rahatlıkla anlaşılabilir.
- ▶ Modelin nasıl ve neden iyi (veya kötü) çalıştığı konusunda öngörü sağlar.
- ▶ Sonuçların paylaşılması oldukça kolaydır.
- ▶ Bu doğrultuda bazı potansiyel kullanım alanları şunlardır:

Karar Ağaçlarının Dezavantajları

- ▶ Özellikle çok sayıda değişken içeren veri kümelerinde ideal olmayabilirler.
- ▶ Bu durumlar, çok fazla karar içeren ve aşırı karmaşık hale gelen ağaç yapılarının oluşmasına neden olabilir.
- ▶ Ayrıca, bu tür karmaşık yapılar karar ağaçlarının veriye aşırı uyum (overfitting) gösterme eğilimini artırabilir.
- ▶ Yine de, bu problemler bazı parametre ayarlarıyla giderilebilir.

Karar Ağaçlarının Temel Yaklaşımı

- ▶ Kök düğüm henüz bölünme gerçekleşmediği için tüm veri kümesini temsil eder.
- ▶ İlk bölünme ideal olarak hedef sınıfı en iyi şekilde tahmin eden değişkende gerçekleştirilir.
- ▶ Her adımda en iyi aday değişken seçilerek yeni bir karar düğümü ve dallar oluşturulur.
- ▶ Bu adımlar aşağıdaki koşullar (biri ya da bazıları) sağlanana kadar devam ettirilebilir.
 - ▶ Düğümdeki örneklerin tamamı (ya da büyük çoğunluğu) aynı sınıfa aitse,
 - ▶ Kalan gözlemleri ayırt edecek başka değişken kalmamışsa,
 - ▶ Ağaç önceden tanımlı bir boyut sınırına ulaşmışsa.

ID3 Algoritması

- ▶ En ayırıcı değişkenleri bulurken entropiden faydalanan bir algoritmadır.
- ▶ Entropi: Bir rastgele değişkenin alabileceği değerlerin ne kadar "karışık" veya "tahmin edilemez" olduğunu gösteren bir ölçüdür.
- ▶ Kesikli bir rasgele değişken için: $-\sum_x p(x) \log p(x)$ ile hesaplanır
- ▶ Kesikli bir rasgele değişken için: $-\int_x p(x) \log p(x) dx$ hesaplanır.
- ▶ Entropi 0-1 arasında değer alır.
- ▶ Küçük entropi değeri sistemde daha az belirsizlik olduğunu gösterir.

ID3 Algoritması

- ▶ ID3, hangi değişkenin kök düğüm veya karar düğümü olacağına kazanım değerine bakarak karar verir. Kazanım, bir değişkene göre ayrıştırma yapıldığında entropideki düşüş miktarını ölçer.
- ▶ $\mathbf{X}$ veri kümesinde S değişkenine göre bölünme yapılması durumunda kazanım:

$$\text{Kazanım}(\mathbf{X}, S) = H(\mathbf{X}) - \sum_{i=1}^m P(X_i)H(X_i)$$

ile hesaplanır. Burada

$$H(\mathbf{X}) = - \sum_{i=1}^c p_i \log p_i$$

dır. m , S değişkenindeki kategori sayısı, c Sınıflama değişkenindeki kategori sayısı, p_i her bir sınıfın ağırlığını gösterir.

Örnek

Cinsiyet	Kilo	Boy	Beden
K	1	3	Orta
K	1	1	Küçük
K	1	1	Orta
K	2	3	Orta
E	2	2	Küçük
K	2	1	Orta
E	2	2	Küçük
E	2	3	Orta
K	3	3	Orta
K	3	4	Büyük
E	3	3	Orta
E	3	3	Küçük
E	4	4	Orta
E	4	5	Büyük
E	5	5	Büyük

Yukarıdaki veri için bir karar ağacı oluşturulmak istensein. Bu durumda kök düğümü belirleyiniz.

Çözüm

Genel entropi:

$$H(X) = - \sum_{i=1}^2 p_i \log p_i = \frac{4}{15} \log \frac{15}{4} + \frac{8}{15} \log \frac{15}{8} + \frac{3}{15} \log \frac{15}{3} = 0.4384$$

Cinsiyet değişkeni için entropi:

$$\text{Entropi kadın: } \frac{1}{7} \log \frac{7}{1} + \frac{5}{7} \log \frac{7}{5} + \frac{1}{7} \log \frac{7}{1} = 0.3458$$

$$\text{Entropi erkek: } \frac{3}{8} \log \frac{8}{3} + \frac{3}{8} \log \frac{8}{3} + \frac{2}{8} \log \frac{8}{2} = 0.47$$

$$\text{Cinsiyeti iinaBrIbklBtoplamlam : } \frac{7}{15} 0.3458 + \frac{8}{15} 0.47 = 0.4120$$

Cinsiyet değişkeni için kazanım ise

$$H(X, \text{Cinsiyet}) = 0.4384 - 0.4120 = 0.0264$$

Kalan adımlar ödev olmakla birlikte diğer değişkenler için kazanımlar

$$H(X, \text{Kilo}) = 0.4384 - 0.3133 = 0.1252$$

$$H(X, \text{Boy}) = 0.4384 - 0.1737 = 0.2648$$

Çözüm (Devam)

- ▶ Buradan en büyük kazanımın Boy değişkeninde olduğu görülür. Dolayısıyla ilk düğüm olarak boy değişkeni seçilmelidir.
- ▶ Bu bölünmeden sonraki parçalanmış veriye benzer işlemler uygulanarak id3 algoritması devam ettirilir ve tüm gözlemlerin gruplanması sağlanır.

Bu

C5.0 Algoritması

- ▶ C5.0, J. Ross Quinlan tarafından geliştirilen C4.5'in gelişmiş sürümüdür; kökeni ID3 algoritmasına dayanır.
- ▶ Herhangi ön işlem olmadan kullanımda çoğu zaman yüksek performans sağlar.
- ▶ C5.0, yorumlanabilirliği ve uygulanabilirliği ile endüstri standardı hâline gelmiştir.
- ▶ Sinir ağları ve destek vektör makineleri gibi "kara-kutu" modellere kıyasla benzer başarı düzeyine ulaşırken daha anlaşılırdır.
- ▶ Zayıf yönleri genellikle kolayca önlenebilir.


C5.0 Algoritması

Güçlü Yönler	Zayıf Yönler
▶ Pek çok problem türünde iyi sonuç veren, çok amaçlı bir sınıflandırıcıdır. ▶ Sayısal, kategorik ve eksik verilerle başa çıkabilen oldukça otomatik bir öğrenme süreci sunar. ▶ Önemsiz değişkenleri dışlar. ▶ Hem küçük hem de büyük veri kümelerinde kullanılabilir. ▶ Matematiksel arka plan olmadan da (küçük ağaçlar için) anlaşılabilir modeller üretir. ▶ Diğer karmaşık modellere göre daha verimlidir.	▶ Karar ağacı modelleri, çok seviyeli değişkenlere göre bölünmelere eğilimlidir. ▶ Modelin aşırı öğrenmesi kolaydır. ▶ Eksenlere paralel bölünmelere bağımlı olması bazı ilişkileri modellemede zorluk yaratabilir. ▶ Eğitim verisindeki küçük değişiklikler, karar mantığında büyük değişimlere yol açabilir. ▶ Büyük ağaçları yorumlamak zordur ve verdikleri kararlar sezgisel gelmeyebilir.

İris verisi

```
# iris verisi R'de önyüklü olan bir veri kümesidir.  
> df<-iris  
> str(df)  
'data.frame': 150 obs. of 5 variables:  
$ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...  
$ Sepal.Width: num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...  
$ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...  
$ Petal.Width: num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...  
$ Species: Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1  
1 1 ...  
  
>plot(df[, -5], col=df$Species)
```


İris verisi saçılım matrisi



Eğitim ve test verilerinin belirlenmesi

```
# 100 gözlem rasgele olarak eğitim verisi olarak belirlenecek
> set.seed(12) # rasgeleliğin her çalıştırmada aynı olmasını sağlar.
# set.seed içindeki sayı değişince rasgele üretilen sayılar da değişir.
> train_sample <- sample(1:125, 85, replace=F)
> train_sample
[1] 66 90 80 119 91 46 69 122 92 34 8 121 82 113 38 108 106 124 103 48
[21] 13 56 68 24 57 72 43 120 30 37 116 39 78 71 26 32 84 20 64 19
[41] 89 4 105 77 96 109 117 27 112 5 18 55 58 83 110 40 52 104 53 94
[61] 28 70 59 61 15 87 7 14 16 10 2 12 42 60 81 101 76 11 22 3
[81] 54 49 45 98 44 47 50 111 75 74 86 107 62 6 1 93 63 100 99 9


> df_train <- df[train_sample, ]
> df_test <- df[-train_sample, ]

> prop.table(table(df_train$Species))
> prop.table(table(df_test$Species))
```

Model uydurulması

```
> model<-C5.0(Species~.,data=df_train)
> summary(model)
Decision tree:
...
Petal.Length <= 1.9: setosa (40)
Petal.Length > 1.9:
:...Petal.Width <= 1.6: versicolor (40/1)
Petal.Width > 1.6:
:...Petal.Length > 5: virginica (15)
Petal.Length <= 5:
:...Sepal.Width <= 2.9: virginica (3)
Sepal.Width > 2.9: versicolor (2)
...
```

Tree Plot



Test verisinde çiçek türlerinin tahmini ve model performansı

```
> pred <- predict(model, df_test)
> pred
[1] setosa setosa setosa setosa setosa setosa setosa ...
[64] virginica virginica
Levels: setosa versicolor virginica

> confusionMatrix(pred,df_test$Species)
      Reference
Prediction setosa versicolor virginica
setosa      10  0  0
versicolor  0  9  5
virginica   0  0 26
```

Örnek 2. – Riskli banka kredilerinin belirlenmesi

```
# Kullanılacak kütüphaneler
# Eğer yüklü değil ise: install.packages("kütüphane adı")
> library(C50)
> library(caret)

# Verinin yüklenmesi
> df<-read.csv("credit.csv",stringsAsFactors = TRUE)
# Burada stringsAsFactors = TRUE argümanı verideki stringleri
# faktörlere dönüştürür.
```

```

> str(df)
'data.frame': 1000 obs. of 17 variables:
 $ checking_balance: Factor w/ 4 levels "1 - 200 DM","< 0 DM",...: 2 1 4 2
 2 4 4 1 4 1 ...
 $ months_loan_duration: int 6 48 12 42 24 36 24 36 12 30 ...
 $ credit_history: Factor w/ 5 levels "critical","good",...: 1 2 1 2 4 2 2
 2 2 1 ...
 $ purpose: Factor w/ 6 levels "business","car",...: 5 5 4 5 2 4 5 2 5 2
 $ amount: int 1169 5951 2096 7882 4870 9055 2835 6948 3059 5234 ...
 $ savings_balance: Factor w/ 5 levels "100 - 500 DM",...: 5 3 3 3 3 5 2 3
 4 3 ...
 ...
 ...
 ...
 $ job: Factor w/ 4 levels "management","skilled",...: 2 2 4 2 2 4 2 1 4 1
 ...
 $ dependents: int 1 1 2 2 2 2 1 1 1 1 ...
 $ phone: Factor w/ 2 levels "no","yes": 2 1 1 1 1 2 1 2 1 1 ...
 $ default: Factor w/ 2 levels "no","yes": 1 2 1 1 2 1 1

```

```
# faktör değişkenler için table, nümerikler için summary
> table(df$checking_balance)
1 - 200 DM < 0 DM > 200 DM unknown
269 274 63 394

> table(df$savings_balance)
100 - 500 DM 500 - 1000 DM < 100 DM > 1000 DM unknown
103 63 603 48 183

> summary(df$months_loan_duration)
Min. 1st Qu. Median Mean 3rd Qu. Max.
4.0 12.0 18.0 20.9 24.0 72.0

> summary(df$amount)
Min. 1st Qu. Median Mean 3rd Qu. Max.
250 1366 2320 3271 3972 18424

> table(df$default)  Hedef sınıf değişkeni
no yes
700 300
```



```
# Rasgele üretilen değerlerin her çalıştırmada aynı olması için:
# İçerideki rakamı kendimiz rasgele belirledik
> set.seed(206)
# Eğitim verisi için gözlem numaraları rasgele olarak belirlenmesi:
> train_sample <- sample(1:1000, 900, replace=F)
> train_sample
173657...718
# Eğitim ve test verisi:
> df_train <- df[train_sample, ]
> df_test <- df[-train_sample, ]

# Hedef sınıf değişkeni eğitim ve test verisi için aynı oranda mı?
> prop.table(table(df_train$default))
> prop.table(table(df_test$default))
```

C5.0 Modelinin uydurulması

```
# Eğitim verisine modelin uydurulması|| >  
model<-C5.0(default~.,data=df_train)  
> summary(model)
```

```
# Uydurulan model kullanılarak test verisinin sınıf değerlerinin  
kestirilmesi
```

```
> pred <- predict(model, df_test)  
> confusionMatrix(pred,df_test$default)
```

Reference

Prediction no yes

no 56 15

yes 13 16

...