

ISB206 Veri Madenciliği

9. Ders: Birliktelik Kuralları

29.04.2026

Birliktelik Kuralları

Bu derste öğrenilecekler:

- ▶ İlişki kuralları, büyük işlem veritabanlarından desen elde etmeye yardımcı olur.
- ▶ Gözetimsiz bir öğrenme yöntemidir.
- ▶ En büyük zorluk, bulunan kural(ilişki) sayısını anlamlı ve yönetilebilir bir seviyede tutmaktır.
- ▶ Bu bölümde Apriori algoritması incelenecektir.
- ▶ Küçük bir süpermarketin bir aylık işlemleri üzerinde uygulanan Apriori algoritması, pazarlama açısından anlamlı pek çok ilişki ortaya koyabilir.
- ▶ Bu yöntemler, çok daha büyük ölçekli perakendecilerde ve perakende dışı projelerde de başarıyla kullanılabilir.

İlişkilendirme Madenciliği Nedir?

İlişki kuralı madenciliği:

- ▶ İşlem veritabanları, ilişkisel veritabanları ve diğer bilgi havuzlarında, öge ya da nesne kümeleri arasında *ilişkiler* olarak adlandırılan sık desenleri bulma sürecidir.

İlişki Kuralları

Kuralın genel biçimi:

- ▶ Ön koşul $\rightarrow$ *Sonuc[destek, guven]*

Genel gösterimi:

- ▶ $\text{buys}(x, \text{"bez"}) \rightarrow \text{buys}(x, \text{"bira"})[\%50, \%60]$

İlişkilendirme Analizi: Temel Kavramlar

- ▶ Veri: Her işlemin bir nesne listesi olduğu bir işlem veri kümesi.
- ▶ Hedef: Bir nesne veya nesne kümesinin varlığı ile başka bir nesne kümesinin varlığı arasında ilişki kuran anlamlı kuralları bulmak.
- ▶ Örnek: Lastik ve oto aksesuarı satın alan müşterilerin %98'i ayrıca oto servis hizmeti de alıyor.

İlişkilendirme Modeli

- ▶ Problem: Kullanıcı tarafından belirlenen minimum destek ve minimum güven eşiğini karşılayan kuralları bulmaktır

Destek (Support):

- ▶ Bir öge kümesinin, veritabanındaki işlemler içinde ne sıklıkla geçtiğini gösterir.
- ▶ $\text{destek}(X) = \frac{\text{X ögesini içeren işlem sayısı}}{\text{Toplam işlem sayısı}}$
- ▶ $\text{destek}(X, Y) = \frac{\text{X,Y birlikte içeren işlem sayısı}}{\text{Toplam işlem sayısı}}$

Güven (Confidence):

- ▶ Bir kuralın, ön koşul gerçekleştiğinde sonucun da gerçekleşme olasılığını gösterir.
- ▶ $\text{güven}(X \rightarrow Y) = \frac{\text{destek}(X, Y)}{\text{destek}(X)}$
- ▶ X gerçekleştiğinde, Y'nin de gerçekleşme olasılığı

Apriori algoritması

1. Minimum destek ve güven değeri belirlenir.
2. Her bir nesnenin destek değeri bulunur.
3. Minimum destek değerinden küçük destekli nesneler dışlanır.
4. Kalan tekli birliktelikler kullanılarak ikili birliktelikler oluşturulur.
5. Minimum destek değerinden düşük ikili birliktelikler dışlanır.
6. Üçlü birliktelikler oluşturulur.
7. Üçlü birlikteliklerden minimum destek değerini geçemeyenler dışlanır.
8. İşlemler minimum destek değerini sağlamayan birliktelikler kalmayana kadar devam ettirilir.
9. Elde edilen sık geçen birliktelikler kullanılarak, başta belirlenen minimum güven değerini sağlayan birliktelik kuralları oluşturulur.

Örnek

Müşteri	Alışveriş
1	Şeker, Çay, Ekmek
2	Ekmek, Peynir, Zeytin, Makarna
3	Şeker, Peynir, Deterjan, Ekmek, Makarna
4	Ekmek, Peynir, Çay, Makarna
5	Peynir, Makarna, Şeker, Soda

Örnek (Algoritma adım 1-3)

1. Eşik değerleri Destek için %60 güven için %75 olarak belirleyelim.
2. Tekil ürünler için destek değerleri:

Ürün	Miktar	Destek
Şeker	3	0.60
Çay	2	0.40
Ekmek	4	0.80
Makarna	4	0.80
Peynir	4	0.80
Deterjan	1	0.20
Soda	1	0.20
Zeytin	1	0.20

- 3 Eşik destek değeri 0.60'dan büyük ürünler Şeker, Peynir, Ekmek ve Makarna harici olanlar çıkarılır.

Örnek (Algoritma adım 4-5)

4 ikili gruplar:

İkili ürün grupları	Sayı	Destek
Şeker, Peynir	2	0.40
Şeker, Ekmek	2	0.40
Şeker, Makarna	2	0.40
Peynir, Ekmek	3	0.60
Peynir, Makarna	4	0.80
Ekmek, Makarna	3	0.60

5 Buna göre destek eşik değeri 0.60'ı aşanlar (Peynir,Ekmek), (Peynir, Makarna), (Ekmek, Makarna)

(Algoritma adım 6-7)

- 6 Destek eşik değerlerini üçlü olarak yalnızca ekmek, makarna ve peynir sağlamaktadır.

Üçlü ürün grupları	Sayı	Destek
Ekmek, Peynir, Makarna	3	0.60

- 7 Ekmek, Peynir, Makarna minimum destek kriterini sağladığı için işlemiden çıkarılmaz.

Örnek (adım 9)

9 Minimum destek (%60) ve güven (%75) eşik değerlerini sağlayan birliktelik kuralları aşağıdaki gibi elde edilir.

$$\text{Güven}(\text{Ekmek}, \text{Makarna} \mapsto \text{Peynir}) = \frac{\text{sayı}(\text{ekmek}, \text{makarna}, \text{peynir})}{\text{sayı}(\text{Ekmek}, \text{Makarna})} = \frac{3}{3} = \%100$$

$$\text{Güven}(\text{Ekmek} \mapsto \text{Makarna}, \text{Peynir}) = \frac{\text{sayı}(\text{ekmek}, \text{makarna}, \text{peynir})}{\text{sayı}(\text{Ekmek})} = \frac{3}{4} = \%75$$

$$\text{Güven}(\text{Peynir} \mapsto \text{Ekmek}, \text{Makarna}) = \frac{\text{sayı}(\text{Ekmek}, \text{Makarna}, \text{Peynir})}{\text{sayı}(\text{Peynir})} = \frac{3}{4} = \%75$$

$$\text{Güven}(\text{Makarna} \mapsto \text{Ekmek}, \text{Peynir}) = \frac{\text{sayı}(\text{Ekmek}, \text{Makarna}, \text{Peynir})}{\text{sayı}(\text{Makarna})} = \frac{3}{4} = \%75$$

$$\text{Güven}(\text{Peynir}, \text{Makarna} \mapsto \text{Ekmek}) = \frac{\text{sayı}(\text{Ekmek}, \text{Makarna}, \text{Peynir})}{\text{sayı}(\text{Peynir}, \text{Makarna})} = \frac{3}{4} = \%75$$

$$\text{Güven}(\text{Peynir}, \text{Ekmek} \mapsto \text{Makarna}) = \frac{\text{sayı}(\text{Ekmek}, \text{Makarna}, \text{Peynir})}{\text{sayı}(\text{Peynir}, \text{Ekmek})} = \frac{3}{3} = \%100$$

R uygulaması (Alışveriş verisi)

```
# Kütüphaneler
> library(arules)

# Veri girişi
> df<-read.csv("groceries.csv",header=F)

# Spam mail verisinde olduğu gibi veriyi farklı formda
# kullanmak gerekmekte
> groceries <- read.transactions("groceries.csv", sep = ",")
```

Veri özeti

```
> summary(groceries)
```

```
transactions as itemMatrix in sparse format with
9835 rows (elements/itemsets/transactions) and
169 columns (items) and a density of 0.02609146

most frequent items:
  whole milk other vegetables    rolls/buns      soda      yogurt    (other)
    2513         1903         1809       1715       1372     34055

element (itemset/transaction) length distribution:
sizes
  1    2    3    4    5    6    7    8    9   10   11   12   13   14   15   16   17   18   19   20   21   22   23
2159 1643 1299 1005  855  645  545  438  350  246  182  117  78  77  55  46  29  14  14   9  11   4   6
  24  26  27  28  29  32
  1    1    1    1    3    1

  Min. 1st Qu.  Median    Mean 3rd Qu.  Max.
  1.000  2.000   3.000  4.409   6.000 32.000

includes extended item information - examples:
  labels
1 Instant food products
2      UHT-milk
3    abrasive cleaner
```

Veri özeti

```
# İlk beş alışverişin incelenmesi
> inspect(groceries[1:5])
# items
[1] {citrus fruit, margarine, ready soups, semi-finished
bread}
[2] {coffee, tropical fruit, yogurt}
[3] {whole milk}
[4] {cream cheese, meat spreads, pip fruit, yogurt}
[5] {condensed milk, long life bakery product, other
vegetables, whole milk}
```

Veri özeti

```
# İlk üç ürün için sıklık oranları (ya da destek oranları)
> itemFrequency(groceries[, 1:3])
Instant food products UHT-milk abrasive cleaner
0.008032537 0.033451957 0.003558719

# Grafikler
# Destek>0.10 olan ürünler
> itemFrequencyPlot(groceries, support = 0.1)
# En yüksek destekli yirmi ürün
> itemFrequencyPlot(groceries, topN = 20)
# İlk 100 alışveriş için alışveriş için yapılan satışlar
> image(groceries[1:100])
```


Modelleme

```
# apriori fonksiyonuyla model kullanılabilir.
# Not: arules kütüphanesi yüklü olmalı
> apriori(groceries)
# apriori fonksiyonu öntanımlı destek eşik değeri: 0.1 .
# Bu değer veri için yüksek olduğundan herhangi kural
# bulunamadı.
> groceryrules <- apriori(groceries, parameter =
  list(support = 0.006, confidence = 0.25, minlen = 2))

# Modelin özeti
> summary(groceryrules)
# Elde edilen kurallardan ilk yirmisi
> inspect(groceryrules[1:20])
```

Model özeti

```
set of 463 rules
```

```
rule length distribution (lhs + rhs):sizes
```

```
  2   3   4  
150 297  16
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
2.000	2.000	3.000	2.711	3.000	4.000

```
summary of quality measures:
```

support	confidence	coverage	lift	count
Min. :0.006101	Min. :0.2500	Min. :0.009964	Min. :0.9932	Min. : 60.0
1st Qu.:0.007117	1st Qu.:0.2971	1st Qu.:0.018709	1st Qu.:1.6229	1st Qu.: 70.0
Median :0.008744	Median :0.3554	Median :0.024809	Median :1.9332	Median : 86.0
Mean :0.011539	Mean :0.3786	Mean :0.032608	Mean :2.0351	Mean :113.5
3rd Qu.:0.012303	3rd Qu.:0.4495	3rd Qu.:0.035892	3rd Qu.:2.3565	3rd Qu.:121.0
Max. :0.074835	Max. :0.6600	Max. :0.255516	Max. :3.9565	Max. :736.0

```
mining info:
```

data	ntransactions	support	confidence
groceries	9835	0.006	0.25

```
call
```

```
apriori(data = groceries, parameter = list(support = 0.006, confidence = 0.25, minlen = 2))
```

```
>
```

Model özeti

	lhs	rhs	support	confidence	coverage	lift	count
1]	{potted plants}	=> {whole milk}	0.006914082	0.4000000	0.01728521	1.565460	68
2]	{pasta}	=> {whole milk}	0.006100661	0.4054054	0.01504830	1.586614	60
3]	{herbs}	=> {root vegetables}	0.007015760	0.4312500	0.01626843	3.956477	69
4]	{herbs}	=> {other vegetables}	0.007727504	0.4750000	0.01626843	2.454874	76
5]	{herbs}	=> {whole milk}	0.007727504	0.4750000	0.01626843	1.858983	76
6]	{processed cheese}	=> {whole milk}	0.007015760	0.4233129	0.01657346	1.656698	69
7]	{semi-finished bread}	=> {whole milk}	0.007117438	0.4022989	0.01769192	1.574457	70
8]	{beverages}	=> {whole milk}	0.006812405	0.2617188	0.02602949	1.024275	67
9]	{detergent}	=> {other vegetables}	0.006405694	0.3333333	0.01921708	1.722719	63
10]	{detergent}	=> {whole milk}	0.008947636	0.4656085	0.01921708	1.822228	88
11]	{pickled vegetables}	=> {other vegetables}	0.006405694	0.3579545	0.01789527	1.849965	63
12]	{pickled vegetables}	=> {whole milk}	0.007117438	0.3977273	0.01789527	1.556565	70
13]	{baking powder}	=> {other vegetables}	0.007320793	0.4137931	0.01769192	2.138547	72
14]	{baking powder}	=> {whole milk}	0.009252669	0.5229885	0.01769192	2.046793	91
15]	{flour}	=> {other vegetables}	0.006304016	0.3625731	0.01738688	1.873834	62
16]	{flour}	=> {whole milk}	0.008439248	0.4853801	0.01738688	1.899607	83
17]	{soft cheese}	=> {other vegetables}	0.007117438	0.4166667	0.01708185	2.153398	70
18]	{soft cheese}	=> {whole milk}	0.007524148	0.4404762	0.01708185	1.723869	74
19]	{specialty bar}	=> {soda}	0.007219115	0.2639405	0.02735130	1.513618	71
20]	{misc. beverages}	=> {soda}	0.007320793	0.2580645	0.02836807	1.479921	72