

ISB206 Veri Madenciliği

2. Ders: Veri Ön İşleme

12.03.2025

Neden veriyi ön işlemeye ihtiyaç duyarız?

- ▶ İlgisiz değişkenleri çıkarmak.
- ▶ Tekrar eden gözlemleri çıkarmak.
- ▶ Kayıp veriler ile başa çıkmak.
- ▶ Sapan değerlerin belirlenmesi.
- ▶ Verileri modellere uygun olacak şekilde düzenlemek ya da dönüştürmek.
- ▶ Veri kümesi içerisindeki tutarsızlıkları belirlemek ve gidermek.

Örnek

Müşteri No	Cinsiyet	Gelir	Yaş	Medeni Durum	İşlem Miktarı
1001	E	72,000	G	E	5000
1002	K	33,000,000	40	D	7000
1003		47,000	45	B	3000
1004	K	62,000	0	B	2000
1005	E	100,000	30	E	5000

Kayıp veri ile başa çıkma yöntemleri

1. Kayıp veri içeren değişken silinebilir. Genellikle değişkenin %90'ından fazlasının kayıpsa bunu tercih edebiliriz.
2. Kayıp veri içeren gözlem silinebilir, ancak bu durum da bilgi kaybına sebep olabilmektedir.
3. Kayıp veri yerine belirli bir değer yazılabilir (Örneğin NA ya da çok büyük ya da küçük bir değer).
4. Kayıp veri nümerik bir değişkende ise ilgili değişkenin ortalama ya da medyanı ile; kayıp veri kategorik bir değişkende ise ilgili değişkenin mod değeri ile değiştirilebilir.
5. Kayıp veriler, regresyon ve sınıflama gibi tahmin yöntemleri ile tahmin edilip doldurulabilir.

Sapan değer

- ▶ Sapan değerler, geri kalan verinin eğilimine aykırı olan uç değerlerdir.
- ▶ Veri girişinde yapılan hataları temsil edebilir.
- ▶ Bazı yöntemler sapan değerlere karşı duyarlı olabilmektedir.

Sapan değer


- ▶ Sapan değerler, geri kalan verinin eğilimine aykırı olan uç değerlerdir.
- ▶ Veri girişinde yapılan hataları temsil edebilir.
- ▶ Bazı yöntemler sapan değerlere karşı duyarlı olabilmektedir.

Genel olarak veri madenciliği yöntemleri sapan değerlerden olumsuz etkilenmeyecek şekilde tasarlanmışlardır. Ancak yine de veri girişinde problemlili durumun belirlenmesi önemlidir.


Sapan değerlerin belirlenmesi

- ▶ Grafikselsel yöntemler: Histogram, Saçılım grafiği, Boxplot, ...
- ▶ Nümerik yöntemler: IQR(inter quartile range), Z skorları, ...


Histogram



Saçılım grafiği



Kutu grafiği



Verilerin dönüştürülmesi

- ▶ Min-Max dönüşümü: Gözlemleri $[0,1]$ aralığına dönüştürmeyi sağlar.

$$X = \frac{X - \min(X)}{\max(X) - \min(X)}$$

- ▶ Z skoru dönüşümü: Gözlemleri 0 ortalamalı 1 standart sapmalı forma dönüştürür.

$$Z = \frac{X - \bar{X}}{S}$$

- ▶ Logaritmik dönüşüm: Sağa çarpık dağılıma sahip verileri simetrikleştirme (normalleştirme) için uygulanır.

$$X_L = \log X$$

Kategorik değişkenlerin tekrar sınıflanması

- ▶ Bazı durumlarda kategorik değişkenler çok sayıda sınıfa sahip olabilmektedir. Bu durum bazı veri madenciliği modellerinin karmaşıklığını artırabilmekte ve/veya daha kötü performans elde etmesine sebep olabilmektedir. Bu durumla başa çıkabilmek için değişken sınıf sayısı daha az olacak şekilde yeni bir değişkene dönüştürülebilir.
- ▶ Örneğin, gözlemlerin yaşadıkları illeri içeren bir değişken (sınıf sayısı 81) coğrafi bölgelere (sınıf sayısı 7), ya da çalışmanın kapsamına göre farklı demografik bölgelere dönüştürülebilir.

Değişkenlerdeki tutarsızlıkların belirlenmesi

Ülke	Frekans
Amerika	1
Fransa	1
ABD	156
Avrupa	46
Çin	34
Japonya	26

Tablo: Arabaların üretildikleri ülkeler için frekans tablosu. Tutarsızlıkları tespit edebildiniz mi?

R prgramı

4. sayfada verilen örnek veri kümesini R'de oluşturmak için

```
> df<-data.frame(no=c(1001,1002,1003,1004,1005),  
                  cinsiyet=c("E","K",NA,"K","E"),  
                  gelir=c(72000,33000000,47000,62000,100000),  
                  yas=c("G",40,45,0,30),medenihal=c("E","D","B","B","E"),  
                  islem=c(5000,7000,3000,2000,5000))  
  
> df # oluşturulan veri kümesini gösterir
```

R'de veri kümesinden değişken çağırma

Önceki sayfada tanımlanan `df` isimli veri kümesinde üçüncü gözlem değişkeni

```
> df[3,]
```

kullanılarak çağrılabilir. Eğer birden fazla değişken çağırmak istiyorsak

```
> df[2:4,]
```

gibi bir komut yazarak ikinci, üçüncü ve dördüncü gözlemleri çağırabiliriz.

R'de veri kümesinden değişken çağırma

Önceki sayfada tanımlanan `df` isimli veri kümesinde cinsiyet değişkeni

```
> df$cinsiyet
```

ya da

```
> df[,2]
```

olarak çağrılabilir

İlgilenilmeye değişkenlerin çıkarılması

Örnek verideki müşteri numarası veri hakkında bir bilgi içermediğinden analizde kullanılmasına gerek yoktur. Böyle bir durumda veriden bu değişkeni çıkarmak için:

```
> df<-df[, -1] # df'den ilk sütunu çıkarır ve df'yi günceller  
> df
```

Sapan değer içeren ikinci gözlemi çıkarmak gerektiği sonucuna varırsak

```
> df<-df[-2,]
```

kullanılabilir.

R'de kayıp gözlem kontrolü

- ▶ Verideki kayıp gözlemleri görmek için

```
> is.na(df)
```

- ▶ Verideki kayıp gözlemlerin sayısını görmek için

```
> sum(is.na(df))
```

- ▶ Kayıp gözlemlerin hangi sütunlarda olduğunu belirlemek için ise

```
> colSums(is.na(df))
```

R de veri dönüşümleri

- ▶ Min-Max ölçekleme için R de aşağıdaki fonksiyonu tanımlayabiliriz.

```
> minmax<-function(x){ (x-min(x))/(max(x)-min(x)) }
```

- ▶ Tanımlanan bu fonksiyon daha sonra gelir değişkenine `> minmax(df$gelir)` şeklinde uygulanabilir.
- ▶ Z skoru dönüşümü için R de hazır olarak `scale` fonksiyonu kullanılmaktadır. Ör:
- ▶ Benzer şekilde logaritma dönüşümü:

```
> log(df$gelir)
```

R de diğer önemli fonksiyonlar

- ▶ Özellikle kategorik değişkenlerde yanlış isimlendirilmiş veri olup olmadığını belirlemek için frekans tablosu `table()` fonksiyonu ile çizdirilir. Ör:

```
> table(df$medenihal)
```
- ▶ `str()` ve `summary()` fonksiyonları ile veri kümesinin farklı formlardaki özetleri elde edilmektedir. Ör:

```
> str(df)  
> summary(df)
```
- ▶ `head()` fonksiyonu veri kümesinin ilk beş elemanını çağırarak kullanılır. Ör:

```
head(iris) # iris R de hazır tanımlı bir veri kümesidir
```
- ▶ R de sırasıyla histogram, saçılım grafiği ve kutu grafiği `hist()`, `plot()` ve `boxplot()` fonksiyonları ile çizdirilir.